


Balanced-MixUp for Highly Imbalanced Medical Image Classification

Balanced-MixUpによる、かなり不均衡な医用画像分類

- 医用画像は一般にデータのクラス分布が不均衡な場合が多く、画像分類を行ってもデータの多いクラスにバイアスがかかり、データの少ないクラスはうまく分類できない。
- 不均衡なクラス分布の解消に効果的なサンプリングする方法がいろいろと提案されていて、その代表がMixUp正規化法である。
- MixUp正規化法は、データとラベルを**ランダムに選んで**加算合成することでデータを拡張する。合成する2つの訓練データ画像を x_i と x_j 、ワンホットエンコーディングされたラベルを y_i と y_j 、合成後の画像とラベルを \hat{x} と \hat{y} とすると、
$$\hat{x} = \lambda x_i + (1 - \lambda) x_j, \hat{y} = \lambda y_i + (1 - \lambda) y_j$$
で表される。
ここで $\lambda \sim \text{Beta}(\alpha, \alpha)$, $\alpha > 0, \lambda \in [0, 1]$ で、 α の一般的な値は $[0.1, 0.4]$ で変化するため、実際には \hat{x} と \hat{y} は x_i, y_i か x_j, y_j に比較的近い可能性がある。

Balanced-MixUp for Highly Imbalanced Medical Image Classification

Balanced-MixUpによる、かなり不均衡な医用画像分類



- 本論文で提案されているBalanced-MixUp法は、「インスタンスベース（上図の S_I ）」と「クラスベース（上図の S_C ）」で教師データを合成する。数式で表すと、
$$\hat{x} = \lambda x_I + (1 - \lambda) x_C, \hat{y} = \lambda y_I + (1 - \lambda) y_C$$
- 図を見ると①クラス毎にデータを複製して②近傍クラスのデータと合成することで、データの少ないクラスのデータ数を増やしている。また、合成結果は元のクラスのウェイトが大きい（ λ が小さい）。
- ランダムにデータを合成するMixUpに比べて、近傍クラスに限定しているところが効果的なのであろうと思われる。

Balanced-MixUp for Highly Imbalanced Medical Image Classification

Balanced-MixUpによる、かなり不均衡な医用画像分類

- 実験に使われたデータ：

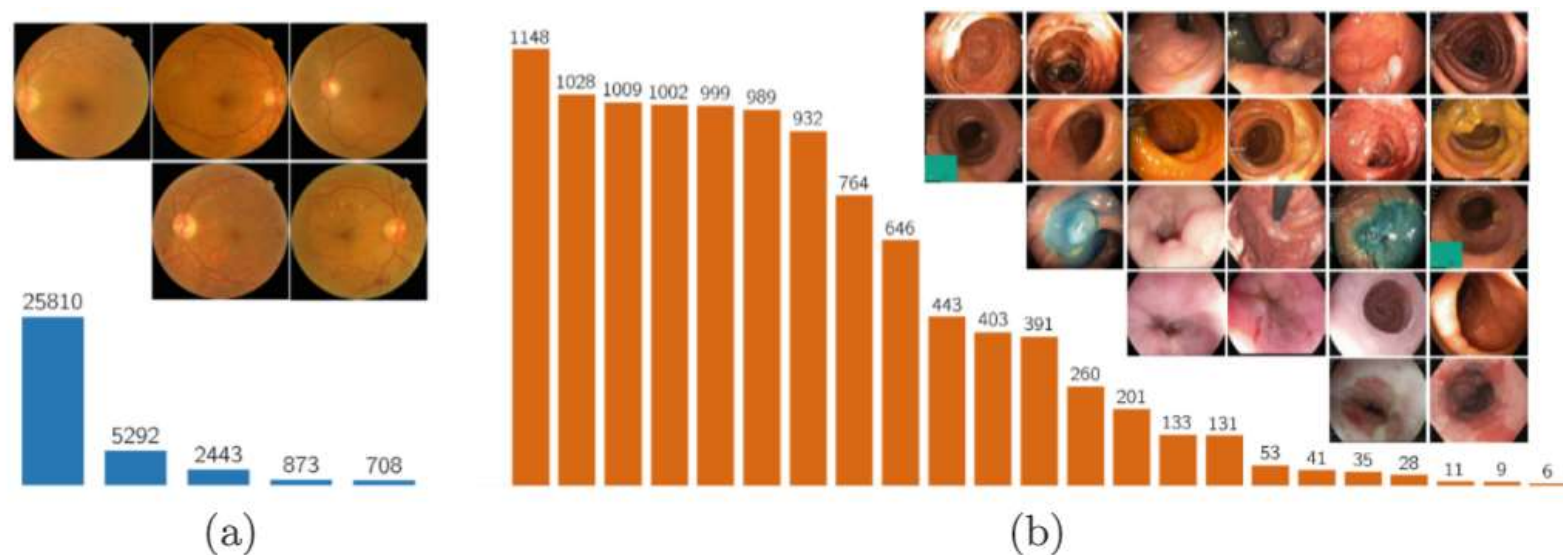


Fig. 1. The two different data imbalance scenarios considered in this paper. Left: Highly imbalanced problem (DR grading from retinal images, $K = 5$ [17]). Right: Long-tailed data (Gastro-intestinal image classification, $K = 23$ [2]).

Balanced-MixUp for Highly Imbalanced Medical Image Classification

Balanced-MixUpによる、かなり不均衡な医用画像分類

- 実験に使われたデータ：

① Eyepacs： Diabetic Retinopathy (DR) grading from retinal fundus images and gastrointestinal image (GI) classification
<https://www.kaggle.com/c/diabetic-retinopathy-detection>

② Hyper-Kvasir： GI image classification
<https://endotect.com/>

③ Messidor-2： 検証用
<https://www.adcis.net/en/third-party/messidor2/>
<https://www.kaggle.com/datasets/google-brain/messidor2-dr-grades>

Balanced-MixUp for Highly Imbalanced Medical Image Classification

Balanced-MixUpによる、かなり不均衡な医用画像分類

- 結果

Table 1. Performance comparison with two different CNN architectures for DR grading on the Eyepacs test set. Best results are marked bold.

	MobileNet V2			ResNeXt-50		
	quad- κ	MCC	Kendall- τ	quad- κ	MCC	Kendall- τ
Class-sampling	74.58	49.34	63.30	74.45	51.12	64.14
Instance-sampling	78.75	61.79	73.39	80.17	62.78	74.32
Sqrt-sampling [21]	79.32	59.66	72.22	79.38	58.77	72.22
Focal Loss [18]	78.59	60.74	72.70	79.73	62.66	73.37
CB Loss [7]	77.84	61.08	72.85	79.19	61.83	74.32
Bal-Mxp: $\alpha = 0.1$	79.61	62.41	74.05	80.35	63.31	74.74
Bal-Mxp: $\alpha = 0.2$	79.43	62.22	73.69	80.78	63.78	75.05
Bal-Mxp: $\alpha = 0.3$	78.34	61.65	73.25	80.62	63.51	74.89

Balanced-MixUp for Highly Imbalanced Medical Image Classification

Balanced-MixUpによる、かなり不均衡な医用画像分類

・結果（つづき）

Table 2. Performance comparison in terms of quad- κ for methods trained on the Eyepacs dataset and tested (no retraining) on Eyepacs and Messidor-2.

	QWKL	DR graduate	Cost-sensitive	Iter. Aug.	Bal-Mxp
	PRL'18 [27]	MedIA'20[1]	MICCAI'20 [9]	TMI'20 [10]	Rx50, $\alpha = 0.2$
Eyepacs	74.00	74.00	78.71	80.00	80.78
Messidor-2	–	71.00	79.79	–	85.14

Table 3. Stratified 5-Fold cross-validation (median) results for GI image classification on the Hyper-Kvasir dataset. Best results are marked bold.

	MobileNet V2			ResNeXt-50		
	MCC	B-ACC	Macro-F1	MCC	B-ACC	Macro-F1
Class-sampling	89.74	61.84	61.84	88.97	59.57	58.40
Instance-sampling	90.49	62.13	62.16	90.74	61.41	61.69
Sqrt-sampling [21]	90.11	63.01	62.66	90.29	62.84	62.85
Focal Loss [18]	90.30	62.09	61.78	90.23	62.12	62.36
CB Loss [7]	85.84	54.93	54.87	89.67	63.84	63.71
Bal-Mxp: $\alpha = 0.1$	90.90	63.49	62.77	91.05	62.55	62.92
Bal-Mxp: $\alpha = 0.2$	90.54	63.44	63.85	91.15	62.80	64.00
Bal-Mxp: $\alpha = 0.3$	90.39	64.76	64.07	90.84	62.34	62.35

参考文献

- MixUp
Zhang, H., Cisse, M., Dauphin, Y.N., Lopez-Paz, D.: mixup: beyond empirical risk minimization. In: International Conference on Learning Representations (2018)
- Balanced-MixUp for highly imbalanced medical image classification
<https://miccai2021.org/openaccess/paperlinks/2021/09/01/068-Paper0936.html>